

# La Regressione Logistica

- E' un problema di classificazione
- L'output è composto da un numero finito di elementi
- Classificazione binaria:
  - l'output può essere solo 0 o 1
- Classificazione su classi multiple:
  - l'output è composto da più di due valori categorici



# La Regressione Logistica

Usualmente si mappa su 0 un esito negativo e su 1 un esito positivo della osservazione

	Classificazione su due classi	
$y = [0, 1]$	1 – Classe OK	0 – Classe KO
Messaggio e-mail	Spam	Non Spam
Tumore	Maligno	Benigno
Transazione	Fraudolenta	Non fraudolenta

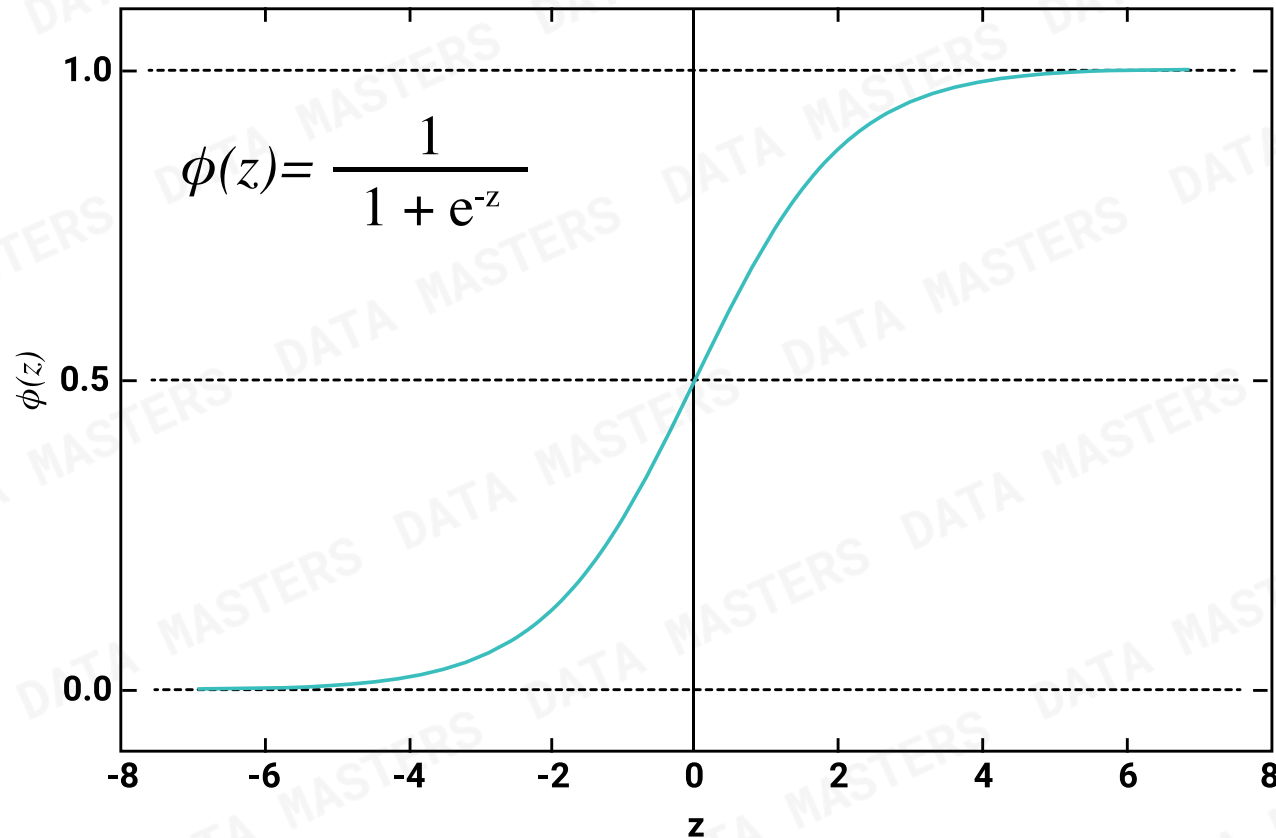
# Classificazione binaria

La funzione ipotesi ha come risultato un numero tra 0 o 1

Non è possibile utilizzare una funzione lineare perché, anche impostando un confine decisionale, i valori inferiori a zero o superiori ad 1 non avrebbero senso



# Funzione Sigmoid



Un esempio di funzione logistica è **la funzione sigmoide**, che restituisce un valore compreso tra 0 ed 1 per ogni valore reale passato in input

# Classificazione binaria

Nel caso della regressione lineare si è utilizzata la formula:

$$\hat{y} = h_{\theta}(x) = \theta_0 + \theta_1 x$$

Per poterla sfruttare nel caso di una regressione logistica, la si può comporre con la funzione sigmoide:

$$\hat{y} = h_{\theta}(x) = \frac{1}{1 + e^{- (\theta_0 + \theta_1 x)}}$$

# Classificazione binaria

$h_{\theta}(x)$  fornisce la probabilità che l'output sia pari ad 1

Ad esempio se risulta pari a 0.7 indica il **70% di probabilità** che, per quel dato input, l'output sia 1

$$h_{\theta}(x) = P(y = 1|x; \theta) = 1 - P(y = 0|x; \theta)$$

$$P(y = 0|x; \theta) + P(y = 1|x; \theta) = 1$$



# Classificazione binaria

Altra rappresentazione equivalente:  $h_{\theta}(x) = g(\theta^T x)$

sigmoide

Vettore parametri  $\theta$

$$g(z) = \frac{1}{1 + e^{-z}}$$

$$z = \theta^T x$$

# Confine decisionale

Per ottenere una classificazione discreta tra 0 e 1, si deve definirne il confine decisionale, che rappresenta la linea che separa l'area dove  $y=0$  da quella dove  $y=1$

ad es. :

$$\begin{array}{ll} h_{\theta}(x) \geq 0.5 \rightarrow y = 1 & g(z) \geq 0.5 \\ h_{\theta}(x) < 0.5 \rightarrow y = 0 & \text{when } z \geq 0 \end{array} \quad g(z) = \frac{1}{1 + e^{-z}}$$

$$z = 0, e^0 = 1 \Rightarrow g(z) = 1/2$$

$$z \rightarrow \infty, e^{-\infty} \rightarrow 0 \Rightarrow g(z) = 1$$

$$z \rightarrow -\infty, e^{\infty} \rightarrow \infty \Rightarrow g(z) = 0$$



# Confine decisionale


Altro esempio:

$$\theta = \begin{bmatrix} 5 \\ -1 \\ 0 \end{bmatrix}$$

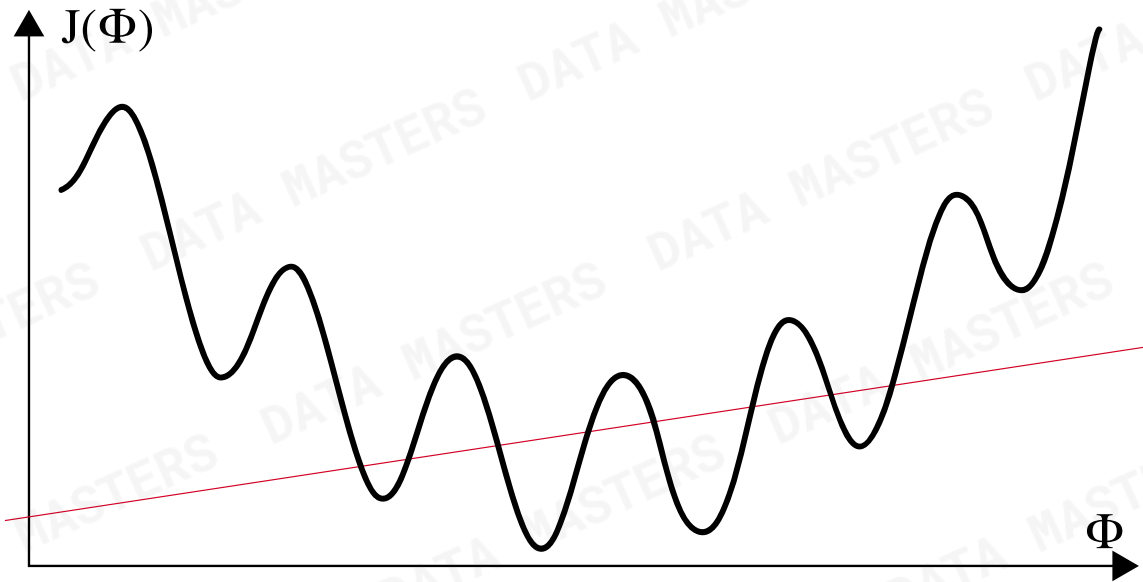
$$y = 1 \text{ if } 5 + (-1)x_1 + 0x_2 \geq 0$$

$$5 - x_1 \geq 0$$

$$x_1 \leq 5$$



# Funzione di costo per la classif. binaria



Come nel caso della regressione lineare, rappresenta la funzione obiettivo dell'ottimizzazione del modello.

L'utilizzo della **funzione di costo** utilizzata nella regressione lineare risulta in una funzione non convessa, dove è più difficile trovare il minimo assoluto tra diversi minimi relativi

$$J(\theta_0, \theta_1) = \frac{1}{2m} \sum_{i=1}^m (\hat{y}_i - y_i)^2 = \frac{1}{2m} \sum_{i=1}^m (h_{\theta}(x_i) - y_i)^2$$

# Funzione di costo per la classif. binaria

Definizione di una funzione di costo «**comoda**» per la classificazione binaria, basandoci sui seguenti vincoli:

$$\text{Cost}(h_{\theta}(x), y) = 0 \text{ if } h_{\theta}(x) = y$$

$$\text{Cost}(h_{\theta}(x), y) \rightarrow \infty \text{ if } y = 0 \text{ and } h_{\theta}(x) \rightarrow 1$$

$$\text{Cost}(h_{\theta}(x), y) \rightarrow \infty \text{ if } y = 1 \text{ and } h_{\theta}(x) \rightarrow 0$$

$$\text{Cost}(h_{\theta}(x), y) = -y \log(h_{\theta}(x)) - (1 - y) \log(1 - h_{\theta}(x))$$

N.B.

**log** è il logaritmo naturale

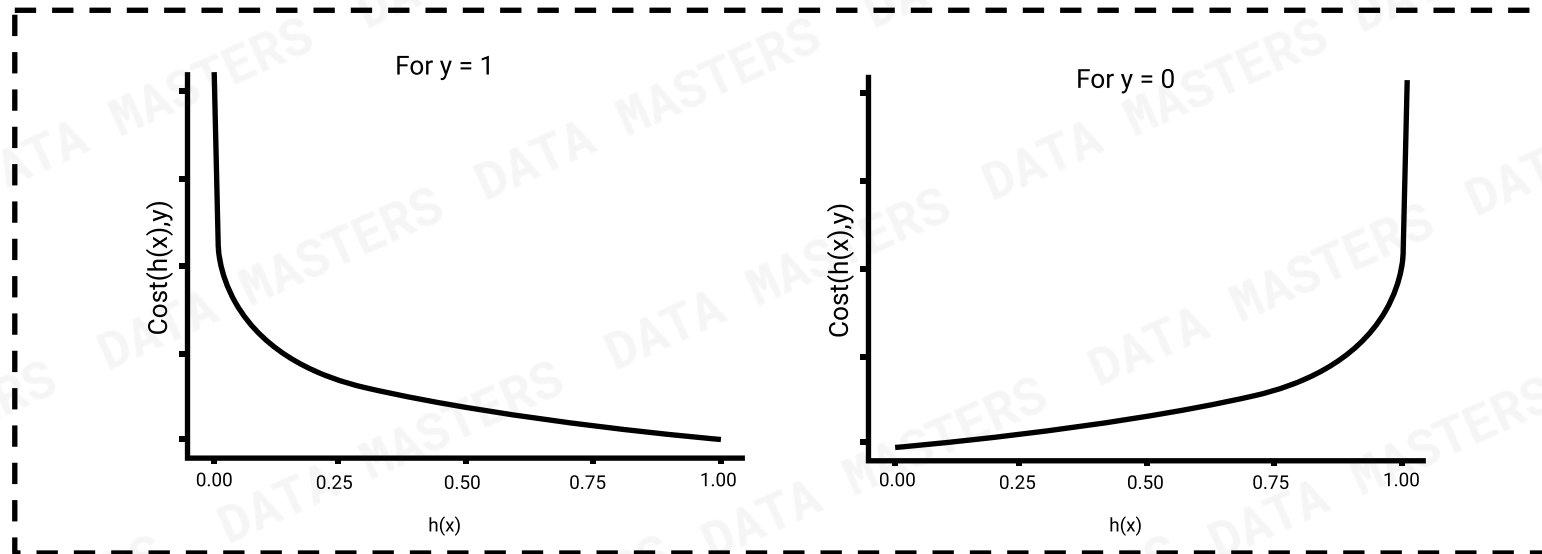
$$\text{Cost}(h_{\theta}(x), y) = -\log(h_{\theta}(x)) \quad \text{if } y = 1$$

$$\text{Cost}(h_{\theta}(x), y) = -\log(1 - h_{\theta}(x)) \quad \text{if } y = 0$$

# Funzione di costo per la classif. binaria

Analisi grafica della funzione di costo per la classificazione binaria:

$$\begin{aligned} \text{Cost}(h_{\theta}(x), y) &= -\log(h_{\theta}(x)) && \text{if } y = 1 \\ \text{Cost}(h_{\theta}(x), y) &= -\log(1 - h_{\theta}(x)) && \text{if } y = 0 \end{aligned}$$



# Funzione di costo per la classif. binaria

Altra forma della funzione di costo:

$$J(\theta) = -\frac{1}{m} \sum_{i=1}^m [y^{(i)} \log(h_{\theta}(x^{(i)})) + (1 - y^{(i)}) \log(1 - h_{\theta}(x^{(i)}))]$$

Riportata in forma vettoriale:

$$h = g(X\theta)$$

$$J(\theta) = \frac{1}{m} \cdot \left( -y^T \log(h) - (1 - y)^T \log(1 - h) \right)$$



# Discesa gradiente per la regressione logistica

Forma generale della discesa del gradiente:

repeat until convergence:  $\theta_j := \theta_j - \alpha \frac{\partial}{\partial \theta_j} J(\theta_0, \theta_1)$

Ricordiamo la definizione della funzione di costo per la Classificazione Binaria:

$$J(\theta) = -\frac{1}{m} \sum_{i=1}^m [y^{(i)} \log(h_{\theta}(x^{(i)})) + (1 - y^{(i)}) \log(1 - h_{\theta}(x^{(i)}))]$$

# Derivata prima della funzione sigmoide

$$\sigma(x)' = \sigma(x)(1 - \sigma(x))$$

$$\begin{aligned}\sigma(x)' &= \left( \frac{1}{1 + e^{-x}} \right)' = \frac{-(1 + e^{-x})'}{(1 + e^{-x})^2} = \frac{-1' - (e^{-x})'}{(1 + e^{-x})^2} = \frac{0 - (-x)'(e^{-x})}{(1 + e^{-x})^2} = \frac{-(-1)(e^{-x})}{(1 + e^{-x})^2} = \frac{e^{-x}}{(1 + e^{-x})^2} \\ &= \left( \frac{1}{1 + e^{-x}} \right) \left( \frac{e^{-x}}{1 + e^{-x}} \right) = \sigma(x) \left( \frac{1 + e^{-x} - 1}{1 + e^{-x}} \right) = \sigma(x) \left( \frac{e^{-x}}{1 + e^{-x}} \right) = \sigma(x)(1 - \sigma(x))\end{aligned}$$

# Derivate prime parziali della funzione di costo

$$\begin{aligned}
 \frac{\partial}{\partial \theta_j} J(\theta) &= \frac{\partial}{\partial \theta_j} \frac{-1}{m} \sum_{i=1}^m \left[ y^{(i)} \log(h_\theta(x^{(i)})) + (1 - y^{(i)}) \log(1 - h_\theta(x^{(i)})) \right] \\
 &= -\frac{1}{m} \sum_{i=1}^m \left[ y^{(i)} \frac{\partial}{\partial \theta_j} \log(h_\theta(x^{(i)})) + (1 - y^{(i)}) \frac{\partial}{\partial \theta_j} \log(1 - h_\theta(x^{(i)})) \right] \\
 &= -\frac{1}{m} \sum_{i=1}^m \left[ \frac{y^{(i)} \frac{\partial}{\partial \theta_j} h_\theta(x^{(i)})}{h_\theta(x^{(i)})} + \frac{(1 - y^{(i)}) \frac{\partial}{\partial \theta_j} (1 - h_\theta(x^{(i)}))}{1 - h_\theta(x^{(i)})} \right] \\
 &= -\frac{1}{m} \sum_{i=1}^m \left[ \frac{y^{(i)} \frac{\partial}{\partial \theta_j} \sigma(\theta^T x^{(i)})}{h_\theta(x^{(i)})} + \frac{(1 - y^{(i)}) \frac{\partial}{\partial \theta_j} (1 - \sigma(\theta^T x^{(i)}))}{1 - h_\theta(x^{(i)})} \right] \\
 &= -\frac{1}{m} \sum_{i=1}^m \left[ \frac{y^{(i)} \sigma(\theta^T x^{(i)}) (1 - \sigma(\theta^T x^{(i)})) \frac{\partial}{\partial \theta_j} \theta^T x^{(i)}}{h_\theta(x^{(i)})} + \frac{-(1 - y^{(i)}) \sigma(\theta^T x^{(i)}) (1 - \sigma(\theta^T x^{(i)})) \frac{\partial}{\partial \theta_j} \theta^T x^{(i)}}{1 - h_\theta(x^{(i)})} \right] \\
 &= -\frac{1}{m} \sum_{i=1}^m \left[ \frac{y^{(i)} h_\theta(x^{(i)}) (1 - h_\theta(x^{(i)})) \frac{\partial}{\partial \theta_j} \theta^T x^{(i)}}{h_\theta(x^{(i)})} - \frac{(1 - y^{(i)}) h_\theta(x^{(i)}) (1 - h_\theta(x^{(i)})) \frac{\partial}{\partial \theta_j} \theta^T x^{(i)}}{1 - h_\theta(x^{(i)})} \right] \\
 &= -\frac{1}{m} \sum_{i=1}^m \left[ y^{(i)} (1 - h_\theta(x^{(i)})) x_j^{(i)} - (1 - y^{(i)}) h_\theta(x^{(i)}) x_j^{(i)} \right] \\
 &= -\frac{1}{m} \sum_{i=1}^m \left[ y^{(i)} (1 - h_\theta(x^{(i)})) - (1 - y^{(i)}) h_\theta(x^{(i)}) \right] x_j^{(i)} \\
 &= -\frac{1}{m} \sum_{i=1}^m \left[ y^{(i)} - y^{(i)} h_\theta(x^{(i)}) - h_\theta(x^{(i)}) + y^{(i)} h_\theta(x^{(i)}) \right] x_j^{(i)} \\
 &= -\frac{1}{m} \sum_{i=1}^m \left[ y^{(i)} - h_\theta(x^{(i)}) \right] x_j^{(i)} \\
 &= \frac{1}{m} \sum_{i=1}^m \left[ h_\theta(x^{(i)}) - y^{(i)} \right] x_j^{(i)}
 \end{aligned}$$


$$\frac{\partial}{\partial \theta_j} J(\theta) = \frac{1}{m} \sum_{i=1}^m \left[ h_\theta(x^{(i)}) - y^{(i)} \right] x_j^{(i)}$$

Forma vettoriale:


$$\nabla J(\theta) = \frac{1}{m} \cdot X^T \cdot (g(X \cdot \theta) - \vec{y})$$

# Esercitazione

Es01\_regressione\_logistica\_discesa\_del\_gradiente.ipynb



# Regressione lineare vs regressione logistica





# Discesa gradiente per la regressione logistica

$$y = \{0, 1 \dots n\}$$

In questo caso si divide il problema in  $n+1$  (+1 perché l'indice inizia da 0) problemi di classificazione binaria; in ciascuno, si prevede la probabilità che 'y' sia un membro della relativa classe.

$$h_{\theta}^{(0)}(x) = P(y = 0|x; \theta)$$

$$h_{\theta}^{(1)}(x) = P(y = 1|x; \theta)$$

...

$$h_{\theta}^{(n)}(x) = P(y = n|x; \theta)$$

$$\text{prediction} = \max_i (h_{\theta}^{(i)}(x))$$

# Esercitazione

Es02\_regressione\_logistica\_su\_più\_classi.ipynb

